

LLM 记忆系统演化：从 ChatGPT 到 Memory OS 与 Neural Memory

研究对象：跨会话个性化、RAG 外部记忆、Agent Memory、LoRA/参数化记忆、Tensor/Latent/Neural Memory、近期纯文本压缩与 Benchmark。

核心论点：没有单一路线“解决记忆”。可落地系统会组合短期上下文压缩、可审计外部记忆、图谱/Agent memory、参数化技能内化与底层 neural/tensor memory。

调研日期

2026-06-03

范围

以 2022 ChatGPT 发布后为主，简述 REALM/RAG/RETRO 等前史。

目标

建立技术脉络、代表论文/项目索引、评估陷阱和 2026 可落地架构。

1. 演化时间线

2020 前史

知识增强而非长期记忆。
Memory Networks、kNN-LM、Transformer-XL、Compressive Transformer 为外部记忆和长上下文提供概念基础。

2020-2021

检索增强预训练/生成。
REALM、RAG、RETRO 让模型在生成时访问外部知识；核心是 knowledge access，不是跨会话 personalization。

2022

ChatGPT：上下文即记忆。早期体验依赖当前窗口，跨会话记忆弱；工程补丁是 conversation buffer、rolling summary、profile note。

2023

Agent memory 兴起。
Generative Agents、MemoryBank、LongMem、MemGPT 把 memory stream、reflection、planning 和 virtual context 带入 agent。

2024

产品记忆与评估出现。
ChatGPT Memory、LoCoMo、LongMemEval、MemoryLLM、ICAE、MemLLM；长期记忆开始

4. 五条主路线：记忆不止一种

上下文
压缩

短期工作记忆。
通过 summary、memento、auto-compact 和 soft tokens 降低上下文成本；适合 coding agent 和长任务恢复。

RAG
图谱

可审计事实记忆。
vector/hybrid search、rerank、GraphRAG、Zep/Graphiti；强在可删、可更新、可引用。

Agent
Memory

行为连续记忆。
memory stream、reflection、procedure、failure experience、self-editing memory；影响 agent 决策和任务执行。

LoRA
参数

内化技能/风格。
SFT、LoRA、adapter、model editing、continual learning；适合稳定高频技能，不适合敏感动态事实。

Tensor
Neural

隐空间长期依赖。
Gist Tokens、ICAE、MemoryLLM、Titans、MIRAS、MSA；潜力高，但审计、删除和权限隔离仍弱。

Memory = 写入过滤 + 表征结构 + 检索编排 +

7. 参数化与 Tensor 内化

LoRA / 参数化记忆

路线	适合	风险
SFT / LoRA	稳定风格、领域模板、procedure	难删、难审计、组合冲突
Model Editing	局部事实修正	locality、泛化、邻近事实破坏
Continual Learning	长期任务适应	灾难性遗忘、数据污染
Sleep Consolidation	把验证后的外部经验巩固为技能	错误记忆被固化

Tensor / Neural Memory

类别	代表	判断
Soft tokens	Gist Tokens、ICAE	高压缩，低可读
Activation/KV	PagedAttention、context cache	工程成熟，但不是长期记忆
FFN memory	MemoryLLM FFN	可分析参数记忆的研究入口
Test-time memory	Titans、MIRAS、MSA	前沿潜力高，治理能力弱

边界：参数和 tensor 内化适合稳定技能与底层能力增强，不适合用户可删事实、企业审计和多租户权限隔离。

被产品化和 benchmark 化。

2025

Memory layer / OS 化。Mem0、A-Mem、MemOS、Zep/Graphiti、LightMem、MIRIX、BEAM；RAG 向 graph、temporal、agentic memory 过渡。

2026

自进化与可治理。EverMemOS、MemRL、TierMem、TencentDB Agent Memory、AgentMemoryBench、LongMemEval-V2；焦点转向生命周期、溯源、遗忘、经验学习。

2. 第一代记忆：上下文与纯文本压缩

机制

把历史直接放进 prompt，或压缩成可读摘要、profile、project notes、session replay。它是最便宜、最可审计的一层。

代表

LLMLingua LongLLMLingua
Selective Context Gist Tokens
ICAE ACON Memento

关键判断

- 摘要会改变证据权重，反复 compact 会造成“记忆腐化”。
- 高质量压缩应保留 raw log 或 evidence pointer。
- 2025-2026 重点从 prompt compression 转向 agent context compaction。

冲突处理 + 遗忘治理 + 评估观测

5. RAG → Graph Memory → Memory OS

RAG 的贡献

把知识外部化；允许更新、删除、引用和权限控制。适合企业文档、业务实体和动态事实。

RAG 的误区

检索命中不等于系统真的记住；top-k chunk 缺少时间、冲突、主体和生命周期。

Graph Memory

把事实组织成人、项目、事件、关系、时间边；Graphiti、GraphRAG、LightRAG、HippoRAG 是代表。

Memory OS

把 plaintext、activation、parametric memory 统一成可治理资源；MemOS、EverMemOS、MemoryOS 是代表。

代表项目谱系

MemGPT/Letta MemoryBank
A-Mem LightMem Mem0
Zep/Graphiti MemOS
EverMind/EverOS
TencentDB Agent Memory

8. Benchmark 与评估陷阱

Benchmark	能力	
LoCoMo	多 session 对话 QA、事件总结	容错策略
LongMemEval	时间推理、知识更新、拒答	现实可度
BEAM	up to 10M tokens、10 类能力	成本
MemBench	factual + reflective memory	需真实
MemoryAgentBench	retrieval、test-time learning、conflict	新场景复杂
AgentMemoryBench	system/personal memory、repair、transfer	更贴近

必须同时测

写入准确率 回忆准确率
冲突处理 遗忘执行 任务收益
成本曲线 可观测性 安全性

陷阱：LLM judge 偏差、答案键错误、只测检索不测生命周期、上下文窗口作弊、自报 benchmark 不等同 SOTA。

3. 产品级记忆

产品	定位	边界
ChatGPT Memory	saved memories + reference chat history; 跨会话个性化	更像用户画像和偏好层，不是完整 agent memory OS
Gemini recall past chats	使用历史对话恢复上下文	偏连续工作流，而非显式记忆对象管理
Claude memory	面向 Team/Enterprise 的工作上下文记忆	强调企业控制、incognito、导入/导出和治理

产品记忆的风险：用户常看不到完整写入和检索过程；错误、敏感和过期记忆需要显式治理。

6. 可落地混合架构

事件日志	append-only：原始对话、工具调用、文件状态、失败分支；用于审计和回放。
短期工作记忆	当前任务窗口 + compacted state；只保留当前子任务需要的信息。
事实/图谱层	atomic facts、entities、relations、time edges、provenance、permissions。
Agent 经验层	procedures、failure cases、tool gotchas、user feedback、reflection。
参数化层	稳定风格、模板、领域技能才进入 LoRA/adapter；保留回滚来源。
Neural/Tensor 层	memory token、KV/activation、FFN memory、test-time neural memory；作为底层增强。
治理层	写入过滤、去重、冲突、过期、删除、敏感信息策略、memory poisoning 防御。

9. 2026 展望

1. 记忆系统会平台化：Memory OS / memory layer 成为 agent 基础设施，而非 prompt 小技巧。
2. 外部记忆仍是主干：审计、删除、权限、来源要求决定 RAG/graph/plaintext 不会消失。
3. 参数化只做后端巩固：稳定、高频、低隐私风险的技能才适合 LoRA/adapter。
4. **Neural memory 会增强底层能力：**超长上下文、多模态和 test-time learning 是主要落点。
5. **竞争点转向治理：**写入过滤、冲突解决、选择性遗忘、溯源、安全和长期稳定。

10. 结论

LLM 记忆的演化不是“更长上下文”一条线，而是从 **context engineering**、**RAG**、**agent memory**、**Memory OS**、参数内化到 **neural/tensor memory** 的多层系统演化。

最现实的架构是混合式：文本压缩负责成本，RAG/图谱负责可审计事实，agent memory 负责行为连续，LoRA/adapters 负责稳定技能，neural/tensor memory 负责底层长程依赖和压缩。

参考文献与项目

- Lewis et al., RAG; Borgeaud et al., RETRO; Park et al., Generative Agents; Zhong et al., MemoryBank; Packer et al., MemGPT.
- LLMingua, LongLLMLingua, Gist Tokens, ICAE, ACON, Memento, Active Context Compression.
- Mem0, Zep/Graphiti, MemOS, EverOS/EverMemOS, LightMem, MemRL, MemEvolve, TierMem, TencentDB Agent Memory.
- Knowledge Editing Survey, Sparse Memory Finetuning, STABLE, How LoRA Remembers, MemoryLLM FFN, Titans, MIRAS, MSA.
- LoCoMo, LongMemEval, BEAM, MemBench, MemoryAgentBench, AgentMemoryBench, EverMemBench.